

# Segmentation des couronnes d'arbres à partir d'images multispectrales pour l'identification des arbres résistants au changement climatique

Frédéric Laplante-Lavoie  
frederic.laplante-lavoie.1@ulaval.ca

Simon Nadeau  
simon.nadeau.12@ulaval.ca

Christopher-Junior Paul  
christopher-junior.paul.1@ulaval.ca

Olga Zamora  
olga-maria.zamora-diaz.1@ulaval.ca

**Résumé**—Ce projet explore la segmentation de couronnes d'arbres à l'aide d'un U-Net enrichi de blocs d'auto-attention, motivé par l'importance économique et écologique des forêts canadiennes face au changement climatique. L'approche adoptée repose sur un modèle multitâche 2D pré-entraîné sur des données de couronne d'arbre au Danemark, choisi pour sa simplicité de traitement, sa maturité architecturale et sa faible exigence en termes de calcul tout en conservant une résolution spatiale suffisante pour la détection des arbres. L'optimisation repose sur une perte de Tversky, adaptée à la nature conservatrice des annotations manuelles, et permettant d'équilibrer la détection et la délimitation lors de la segmentation. Les résultats montrent une bonne généralisation du modèle RGB optimisé, avec des performances stables entre les phases d'entraînement, validation et test, bien que des différences importantes aient été observées en fonction des caractéristiques visuelles des sites. En particulier, la densité des arbres et le contraste des images influencent fortement la qualité des détections. Ces observations confirment le potentiel des architectures 2D pour la segmentation de couronnes d'arbres en télédétection, tout en soulignant l'importance de l'adaptation fine des hyperparamètres.

## I. INTRODUCTION

Les forêts du Canada sont essentielles à notre économie, société et culture, et leur gestion durable est cruciale pour les générations actuelles et futures. Cependant, le Canada pourrait connaître un réchauffement climatique jusqu'à quatre fois plus rapide que la moyenne mondiale (4 à 8 °C d'ici 2100) [1], ce qui aura des répercussions importantes sur les forêts, qui couvrent la moitié du territoire.

Pour adapter les forêts au changement climatique, il est nécessaire d'identifier les arbres plus résistants. En collaboration avec Ressources Naturelles Canada, notre équipe a travaillé sur la délimitation des couronnes d'arbres dans des études de génétique forestière. Les images multispectrales permettent de mesurer rapidement des caractéristiques liées à la croissance et à la résistance des arbres (par exemple, indices de végétation, phénologie). Ces données soutiendront les programmes d'amélioration génétique pour sélectionner des arbres en bonne santé et productifs.

Les drones ont révolutionné la cartographie des forêts grâce à leurs capteurs avancés, tels que les caméras haute résolution et les scanners LiDAR. La segmentation des données UAV est essentielle pour analyser individuellement les arbres et mesurer les indices de végétation, tels que le NDVI. Les

approches traditionnelles de traitement des données, telles que la délimitation des vallées et la segmentation par ligne de partage des eaux, nécessitent souvent des ajustements manuels et sont sensibles aux variations de qualité des images [2], [3].

Les méthodes basées sur l'apprentissage profond, comme les réseaux de neurones convolutifs (CNN) et les approches YOLO, sont plus efficaces pour les grandes zones (>100 ha) et offrent une meilleure généralisation et robustesse [4]. Parmi ces méthodes, les approches de détection d'objets (R-CNN, Mask R-CNN [5], YOLO [6]) et les méthodes de segmentation sémantique (U-Net [7], DeepLabV3+ [8]) sont particulièrement reconnues.

Ce projet vise à tester l'efficacité d'un réseau CNN pour la segmentation des arbres, en s'inspirant des efforts déployés pour l'inventaire forestier national (NFI) du Danemark [9]. Leur approche, validée sur des images aériennes de Finlande, de France et des États-Unis, démontre la polyvalence de leur méthode et la possibilité d'estimer la hauteur des arbres sans données LiDAR supplémentaires.

## II. ÉTAT DE L'ART

Notre démarche a débuté par une analyse détaillée de l'état de l'art concernant la segmentation individuelle d'arbres à l'aide de données LiDAR et multispectrales.

Le tableau V (annexe 1) présente une sélection d'études pertinentes conduites en conditions naturelles et publiées majoritairement dans des revues spécialisées au cours des deux années précédentes. Conformément à la portée de notre projet, cette revue s'est limitée aux systèmes de données aériennes. Deux grandes catégories d'approches se distinguent : les méthodes bidimensionnelles (2D) et tridimensionnelles (3D).

Les approches 2D exploitent principalement des images aériennes ou satellitaires enrichies d'informations spectrales (RGB, multispectrale). Ces méthodes utilisent des architectures de réseaux de neurones convolutifs (CNN) établies pour la détection d'objets (Faster R-CNN, YOLO), la segmentation sémantique (U-Net) ou la segmentation d'instances (Mask R-CNN). Bien que dépendantes de la résolution spatiale des images, ces approches ont démontré leur efficacité pour la segmentation d'instances et sémantique dans divers types de forêts, avec un volume de données d'entraînement variable.

Les approches 3D s'appuient sur des données LiDAR, qui fournissent des informations tridimensionnelles précises sur la structure de la végétation sous forme de nuages de points. Ces méthodes utilisent des architectures de réseaux neuronaux 3D (ex. 3D U-Net) ou des approches combinant des réseaux 2D et des techniques de traitement de nuages de points. Elles permettent une segmentation d'instance, sémantique et panoptique, offrant une compréhension plus riche de la structure des arbres et de la canopée. Les données d'entraînement peuvent provenir de différentes plateformes LiDAR (terrestre : TLS, aéroporté : ALS, drone : UAV, véhicule en mouvement : MLS).

### III. DESCRIPTION DE L'APPROCHE PROPOSÉE

Nous avons choisi l'approche 2D pour 1) la simplicité du traitement des données 2D brutes; le traitement de nos nuages de points LiDAR 3D nécessite des algorithmes spécifiques pour l'organisation et le traitement des voisins, ce qui ajoute une couche de complexité. À différence d'une image 2D, qui est une grille régulière de pixels, où la position relative des pixels est implicite; 2) la maturité d'architectures des modèles d'apprentissage profond 2D; 3) la manipulation de grands nuages de points et les opérations de convolution 3D sont intrinsèquement plus coûteuses en calcul (RAM, GPU) que leurs équivalents 2D et finalement; 4) on dispose des données avec une résolution spatiale suffisamment fine, les détails de la couronne de chaque arbre sont suffisamment clairs pour permettre une segmentation précise basée sur les caractéristiques 2D.

Nous avons adapté notre travail sur l'article et le code publié par *Li et al. 2023 (TreeCountSegHeight)* [10] pour 1) la reproductibilité de la recherche, nous avons pu comprendre exactement comment le modèle a été implémenté, entraîné et évalué en ayant un code source public [11]; 2) leur modèle pré-entraîné a déjà appris des caractéristiques générales à partir d'un grand ensemble de données (19 771 arbres provenant de peuplements variés).

L'approche originale repose sur l'utilisation de deux modèles distincts, le premier traite conjointement les tâches de comptage et de segmentation, qui inclut un modèle de hauteur de la canopée (MHC). L'objectif du deuxième modèle est de prédire la hauteur de la canopée.

Dans le cadre de notre projet, on a utilisé le premier modèle seulement et nous avons choisi de ne pas utiliser le MHC, car son impact sur l'amélioration de l'IFN pour le Danemark s'est avéré limité. Le premier modèle est un réseau d'apprentissage profond multi-tâches avec deux branches partiellement connectées pour les tâches de comptage des arbres et de segmentation des couronnes (Fig. 1).

La première branche du réseau effectue la tâche de segmentation sémantique des couronnes en ayant comme objectif d'assigner à chaque pixel une étiquette indiquant s'il appartient à une couronne d'arbre ou à l'arrière-plan. Pour ce faire, une fonction d'activation sigmoïde a été utilisée dans la couche de sortie finale. La sigmoïde produit des valeurs de probabilité dans la plage de  $[0, 1]$ , qui ont ensuite été




FIG. 1 – Approche du modèle 1

converties en étiquettes binaires en appliquant un seuil de 0,5.

La deuxième branche du réseau prédit une carte de densité qui représente la probabilité qu'un arbre soit centré autour de chaque pixel. Le nombre total d'arbres dans une image est estimé en sommant toutes les valeurs de la carte de densité. La génération de la vérité terrain pour les cartes de densité a été effectuée en appliquant des noyaux gaussiens 2D centrés sur les délimitations manuelles des couronnes.

L'architecture U-Net a été utilisée en y intégrant des blocs d'auto-attention (Attention U-Net). Ces blocs sont stratégiquement placés pour extraire des informations plus pertinentes du chemin de sous-échantillonnage du réseau. Pour stabiliser le processus d'entraînement et accélérer la convergence, une normalisation par batch a été appliquée après chaque couche de convolution.

Un point particulier de l'architecture est que la majorité des poids du modèle sont partagés entre les deux branches (segmentation et comptage) à l'exception des poids des couches finales, qui sont responsables de la production des prédictions spécifiques à chaque tâche. Ce partage de poids permet au réseau d'apprendre des représentations communes et robustes à partir des données d'entrée, tout en conservant la capacité de produire des sorties distinctes pour chaque tâche.

### IV. MÉTHODOLOGIE ET EXPÉRIMENTATION

#### A. DONNÉES

Notre projet s'appuie sur un ensemble de données provenant de sept plantations en Colombie-Britannique représentant 15 130 arbres (Tableau IV, annexe 1) et deux espèces principales : le cèdre rouge du Canada (Fig. 2, *Thuja plicata* Donn ex D.Don) et le sapin de Douglas (Fig. 3, *Pseudotsuga menziesii* Mirbel). Chaque plantation (ou site) est composée d'arbres appartenant à une seule espèce et ayant le même âge. Quatre de ces plantations sont peuplées de cèdres rouges du Canada comprenant un total de 10 196 arbres et ayant des âges variant de 10 à 23 ans au moment de la collecte des données. Les trois autres sites sont constitués de sapins de Douglas (total de 4 934 arbres) et une gamme d'âges allant de 4 à 23 ans. La résolution multispectrale de 10 bandes varie entre 2,48 et 4,7 cm/pixel selon les sites, reflétant la finesse du détail capturé pour chaque plantation.

Des données de référence étaient indispensables pour entraîner et évaluer la performance des algorithmes de seg-




FIG. 2 – Cèdre rouge du Canada mature, site **CW East Main**



FIG. 3 – Sapin de Douglas mature, site **FDC East Main**

mentation. Les étiquettes cibles ont été fournies par RNCAN. Les délimitations des couronnes d'arbres ont été générées à partir de supercellules, soumises à trois étapes de filtrage successives au moyen d'un algorithme fondé sur des règles, sans recours à l'apprentissage automatique. Premièrement, des cercles proportionnels à 10 % du 99e percentile (Fig. 4) de hauteur de chaque arbre ont affiné les supercellules, les limitant aux zones visibles du dessus et minimisant le chevauchement des branches avec les arbres voisins, assurant ainsi une segmentation conservatrice. Deuxièmement, les supercellules recouvrant des zones de hauteur maximale supérieure à 50 % du 99e percentile ont été éliminées, excluant de fait les petits arbres. Troisièmement, un filtre a supprimé les supercellules présentes dans plus d'une segmentation, garantissant des délimitations non chevauchantes. Les couronnes cibles finales ont été raffinées manuellement pour s'assurer qu'elles soient conservatrices, c'est-à-dire que tous les pixels inclus à l'intérieur d'une couronne appartiennent au bon arbre (Fig. 5).




FIG. 4 – Délimitation initiale des supercellules

Il est à noter que des arbres de la même espèce que notre cible sont présents en bordure à l'extérieur de la plantation. Ces arbres n'ont pas été inclus dans notre ensemble cible car ils ne font pas partie de la zone d'étude génétique (Fig. 6) à l'intérieur de laquelle les arbres sont identifiés et mesurés pour le suivi à long terme (Fig. 7).

## B. PRÉTRAITEMENT

1) *Images et bandes multispectrales*: Nous avons sélectionné les bandes RGB ainsi que les bandes RGB +




FIG. 5 – Délimitation finale, segmentation conservatrice




FIG. 6 – Délimitation de la zone d'étude



FIG. 7 – Couronnes identifiées

NIR (proche infrarouge), tout en conservant la résolution d'origine, soit entre 2,48 et 4,7 cm/pixel. Ensuite, nous avons normalisé les pixels entre 0 et 255. Enfin, nous avons corrigé certains artefacts (valeurs N/A) présents dans les bandes pixelisées en les remplaçant par la valeur 0.

2) *Délimitation la zone d'étude*: Nous avons d'abord délimité la zone d'étude servant à l'entraînement (Fig. 8), la validation et le test des modèles à l'aide d'un polygone tracé à la main. Cette délimitation était nécessaire afin de conserver seulement la zone d'étude, à l'intérieur de laquelle les arbres d'intérêts (arbres suivis au niveau génétique) ont été assignés à des étiquettes cibles.




FIG. 8 – Délimitation la zone d'étude, site **FDC PR Canoe**






FIG. 9 – Séparation du jeu de données en entraînement, validation et test (site **FDC PR Canoe**)

3) *Séparation du jeu de données*: Étant donné la petite taille des plantations et pour avoir un jeu d'entraînement suffisamment grand, nous avons divisé le jeu de données en entraînement/validation/test selon les proportions de 80%/10%/10% (Fig. 9). Pour ce faire, nous avons divisé la zone d'étude en grille de 30m x 30m. Cette taille de tuile a été choisie suffisamment grande pour contenir un bon nombre d'arbres et éviter de séparer trop d'arbres entre les tuiles. Une tuile devait contenir un minimum de 10 arbres pour être incluse dans la zone d'étude. Nous avons tiré aléatoirement 10% des tuiles pour le jeu de validation, ainsi qu'un autre 10% pour le jeu de test. Étant donné que les tuiles en bordure de la zone d'étude ne sont pas carrées, l'aire de la surface en validation varie de 11% à 15% et l'aire en test varie de 9% à 16%. Le jeu de données de validation a servi pour la sélection des hyperparamètres (ex : entrée RGB ou RGB + NIR, poids des espaces entre les arbres dans la fonction de perte). Le jeu de test a été utilisé seulement pour l'évaluation finale de notre meilleur modèle.

### C. FINE-TUNING

Les comparaisons entre les couronnes étiquetées et délimitées reposent souvent sur le score d'Intersection sur Union (IoU), également appelé indice de Jaccard. Bien que l'IoU soit une mesure courante du chevauchement ou de la similarité lors de la délimitation d'objets, il suppose que la vérité terrain est une représentation précise de la couronne réelle. Par conséquent, il ne tient pas compte de l'erreur de mesure potentiellement importante dans les limites des couronnes étiquetées par des humains. Compte tenu de la nature conservatrice de nos étiquettes cibles, nous utilisons la perte de Tversky, une généralisation du score f1, pour

ajuster l'importance des faux positifs et des faux négatifs. Afin de tenir compte des couronnes d'arbres qui pourraient se chevaucher dans les sites matures, rendant la séparation et le comptage de leurs couronnes complexes, les espaces entre les couronnes voisines ont été mis en évidence dans la fonction de perte. Les pixels représentant les espaces entre les arbres ont été assignés un poids ( $w_i$ , désigné ci-après par "*poids de frontière*") plus élevé dans la fonction de perte pour la segmentation, afin d'améliorer la capacité du modèle à distinguer les limites des couronnes adjacentes.

Soit  $I_n$  une image d'entraînement, et  $p_{0i} \in [0, 1]$  la probabilité prédite que le pixel  $i \in I_n$  appartienne à un arbre. On note  $g_{0i} = 1$  si le pixel  $i$  est un objet (et 0 sinon). On définit également  $p_{1i} = 1 - p_{0i}$  et  $g_{1i} = 1 - g_{0i}$ . Chaque pixel est pondéré par un poids  $w_i$ , permettant de tenir compte de son importance relative. La fonction de perte de Tversky pondérée, calculée pixel par pixel, est alors donnée par :

$$\mathcal{L}_{\text{seg}} = 1 - \frac{\sum w_i p_{0i} g_{0i}}{\sum w_i (p_{0i} g_{0i} + \alpha p_{0i} g_{1i} + \beta p_{1i} g_{0i})} \quad (1)$$

où  $\alpha$  et  $\beta$  sont des coefficients permettant d'ajuster l'importance relative des faux positifs et des faux négatifs. Nous avons utilisé les mêmes valeurs de  $\alpha=0.6$  et  $\beta=0.4$  que l'article original afin de pénaliser davantage les faux positifs et demeurer conservateur dans la délimitation des couronnes.

Pour l'entraînement (fine-tuning), les zones d'entraînement et de validation déterminées au préalable ont été divisées aléatoirement en tuiles de 256x256 pixels. Nous avons appliqué la normalisation z-score aux tuiles (moyenne de 0 et écart-type de 1) avant l'entrée dans le modèle. Nous avons utilisé l'optimiseur Adam avec un taux d'apprentissage de  $1e-4$ ,  $\beta_1=0.9$ ,  $\beta_2=0.999$ , et une taille de batch de 8 tuiles. Un horaire de réduction du taux d'apprentissage avec une patience de 4 époques et un facteur de 0.33 a été programmé (ReduceLROnPlateau). Nous avons roulé chacun des modèles pendant 10 époques et nous avons conservé le modèle ayant la perte la plus faible sur le jeu de validation.

Pour la recherche d'hyperparamètres, nous avons fait varier les bandes en entrée du modèle (RGB ou RGB+NIR et le poids de frontière (tableau I). Finalement, nous avons tenté d'entraîner les modèles sur une seule espèce à la fois.

TABLE I – Recherche d'hyperparamètres

| Configuration | Espèce(s)        | Poids de frontière |
|---------------|------------------|--------------------|
| 1. RGB        | Toutes           | [2, 3, 4, 5]       |
| 2. RGB + NIR  | Toutes           | [1.1, 1.5, 2.5, 3] |
| 3. RGB        | Une seule espèce | [3]                |

### D. ÉVALUATION DU MODÈLE

Nous avons évalué les résultats de la segmentation en utilisant le score f1, la précision, le rappel, et le IoU moyen (mIoU).

## V. RÉSULTATS ET DISCUSSIONS

Le tableau II compare les performances des modèles selon le type d'entrée et le poids de frontière. Le meilleur



compromis est atteint par le modèle RGB avec un poids de frontière de 3.0 et testé sur toutes les espèces, affichant un mIoU de 0.590 et un F1-score de 0.607, en moyenne sur l'ensemble des sites (jeu de validation). L'ajout de la bande NIR n'améliore pas systématiquement les résultats : malgré une précision plus élevée (jusqu'à 0.861), le rappel diminue sensiblement (jusqu'à 0.412), traduisant une tendance à manquer des couronnes. Enfin, un poids de frontière trop faible (2.0) ou trop élevé (5.0) nuit à l'équilibre précision/rappel, confirmant l'importance d'un réglage équilibré entre la taille des couronnes prédites et la délimitation entre les arbres. Nous nous sommes donc concentrés sur le modèle RGB avec des poids de frontière de 3.

TABLE II – Métriques moyennes par modèle et poids de frontières sur l'ensemble des sites, jeux de données de validation

| Modèle | Poids | mIoU  | F1-Score | Precision | Recall |
|--------|-------|-------|----------|-----------|--------|
| RGB    | 2.0   | 0.522 | 0.435    | 0.686     | 0.387  |
| RGB    | 3.0   | 0.590 | 0.607    | 0.833     | 0.546  |
| RGB    | 4.0   | 0.552 | 0.481    | 0.813     | 0.437  |
| RGB    | 5.0   | 0.561 | 0.506    | 0.856     | 0.445  |
| RGBNIR | 1.5   | 0.565 | 0.544    | 0.842     | 0.469  |
| RGBNIR | 3.0   | 0.540 | 0.499    | 0.861     | 0.412  |

Le modèle RGB avec un poids de frontière de 3.0 présente des performances stables entre les phases d'entraînement, de validation et de test (tableau III). Les scores de mIoU et de F1 varient peu (entre 0.561 et 0.607), indiquant une bonne généralisation. La précision reste élevée dans toutes les phases ( $> 0.80$ ), tandis que le rappel, plus faible, augmente de l'entraînement (0.483) à la validation (0.546), puis se stabilise en test (0.500), suggérant un compromis équilibré entre détection des couronnes et limitation des faux positifs. De plus, notre phase d'entraînement par rapport à la fonction de perte démontre une convergence de la courbe d'entraînement aux alentours de 8-9 époques, tandis que la courbe de validation tend à se stabiliser, après 2-3 époques. Une présentation des courbes est présentée ci-haut (Fig. 10). À noter que le modèle a été préentraîné pendant 1400 époques avant l'exécution des 10 époques.

TABLE III – Métriques moyennes par phase sur l'ensemble des sites, modèle RGB avec poids de frontière de 3

| Phase      | mIoU  | F1-Score | Precision | Recall |
|------------|-------|----------|-----------|--------|
| train      | 0.565 | 0.561    | 0.808     | 0.483  |
| validation | 0.590 | 0.607    | 0.833     | 0.546  |
| test       | 0.576 | 0.574    | 0.804     | 0.500  |

La figure 11 révèle des écarts significatifs de performance entre les sites du jeu de test. Le site **FDC JR East GCA** affiche les meilleures métriques dans son ensemble, avec un F1-score de 0.75, un rappel de 0.80 et un mIoU de 0.69. Ces résultats semblent s'expliquer par une meilleure qualité




FIG. 10 – Courbe d'entraînement et de validation

visuelle de l'image (voir figure 12), avec un contraste plus net entre les couronnes d'arbres, facilitant la délimitation. Les prédictions du modèle  $y$  sont cohérentes et souvent bien alignées avec les annotations, même si les délimitations fournies restent conservatrices sur ce site aussi. À l'inverse, le site **CW JR Sandcut** présente un rappel beaucoup plus faible (0.41), malgré une bonne précision (0.77), ce qui indique une difficulté à détecter toutes les couronnes. Cela semble lié à la proximité importante des arbres, à un contraste plus faible entre les individus, et à des annotations très restreintes en surface par rapport à la taille apparente des couronnes. Enfin, le site **FDC PR Canoe** se démarque comme un cas problématique avec des résultats extrêmement faibles ( $F1=0.04$ ,  $\text{rappel}=0.02$ ). L'image  $y$  est très bruitée (présence de taches blanches), avec des zones masquées ou absentes, une couverture incomplète, et plusieurs arbres manifestement omis dans les annotations. Ces conditions se révèlent difficiles pour le modèle afin d'effectuer la segmentation, et expliqueraient les échecs observés. Ces observations soulignent l'importance cruciale de la qualité des données et des annotations dans les performances de segmentation.

En dernier lieu, nous avons entraîné un modèle pour chaque espèce pour tenter d'améliorer les performances sur les sites problématiques. Pour le modèle entraîné sur les sites de cèdre rouge, nous avons plutôt obtenu une dégradation de la performance pour deux des quatre sites et une performance similaire pour les deux autres sites, par rapport à notre modèle multi-espèces choisi. Par exemple, pour le site **CW JR Sandcut**, le rappel a chuté à 0.02 et la précision à 0.67. Pour le modèle entraîné seulement sur les sites de sapin de Douglas, nous avons également vu une dégradation des performances sur le site **Fdc JR W45** pour lequel le modèle n'a prédit aucune couronne (prédictions de 0 sur tous les pixels). Sur ce site, les arbres sont très jeunes et les espaces entre les arbres sont vastes, ce qui induit un fort déséquilibre entre les classes. Ces résultats indiquent que d'entraîner en utilisant les 7 sites et les deux espèces permet au modèle de mieux généraliser grâce à un plus grand jeu de données, couvrant des domaines différents (espèces et sites).

Les résultats de notre modèle final sur le jeu de test ( $f1 = 0.57$ ,  $\text{rappel} = 0.50$ ,  $\text{précision} = 0.80$ ) sont inférieurs à ceux obtenus par *Li et al. 2023 (TreeCountSegHeight)* [10] sur le jeu de données du Danemark ( $f1 = 0.77$ ,  $\text{rappel} =$





FIG. 11 – Métriques par site, jeux de données de test

0.69, précision = 0.96, Li et al. 2023). Également, Li et al. 2023 ont noté une légère amélioration de la performance avec le modèle RGB + NIR vs. RGB, alors que nous avons observé une dégradation des performances sur nos données. La performance plus faible sur nos données peut être due à des différences de compositions d'espèces et de structure de peuplement, mais possiblement surtout à la qualité inférieure de nos étiquettes. Nos couronnes étiquetées sont très conservatrices (plus petites que l'arbre), ce qui génère beaucoup de faux positifs lors de la prédiction, qui sont pénalisés plus fortement ( $\alpha=0.6$ ). Ce qui a résulté en des couronnes prédites généralement plus petites que les cibles. Il est donc possible que de pénaliser moins fortement les faux positifs dans la fonction de perte  $\alpha$  améliore la performance.


## VI. CONCLUSION

Dans ce projet, nous avons exploré le transfert de représentation et le *fine-tuning* d'un modèle de segmentation de couronnes d'arbres basé sur l'architecture U-Net enrichie de blocs d'auto-attention, appliqué à des images multispectrales de plantations canadiennes. Nos résultats démontrent que les modèles préentraînés sur un autre territoire (Danemark) parviennent à généraliser partiellement, atteignant des scores intéressants sur l'ensemble des sites.


Les métriques utilisées (mIoU, F1-score, précision et rappel) ont permis de quantifier les forces et limites du modèle selon différents contextes. Nous avons observé une performance robuste pour la détection des couronnes bien définies, mais une sensibilité accrue dans les zones de chevauchement ou de faible résolution. L'équilibre entre précision et rappel varie selon les sites, suggérant que des



(a) FDC JR East GCA



(b) CW JR Sandcut



(c) FDC PR CANOE

FIG. 12 – Vue de la prédiction (plaques jaunes en transparence) et de l'annotation (bordures rouges)

ajustements spécifiques par type de plantation ou densité forestière pourraient améliorer la performance.

Pour les travaux futurs, l'intégration de données LiDAR ou de modélisations 3D pourrait permettre une meilleure distinction des couronnes dans les zones denses. De même, l'adaptation dynamique des poids dans la fonction de perte, selon la configuration spatiale des arbres, pourrait offrir une amélioration tangible de la délimitation. Enfin, le fine-tuning de modèles fondationnels préentraînés sur de grandes quantités de données 2D (ex. : SAM [12]) ou 3D (ex. : Sonata [13]) pourrait constituer une avenue prometteuse [14].

Ce projet confirme la pertinence de l'apprentissage profond pour la cartographie forestière, tout en soulignant la nécessité d'approches adaptatives pour tenir compte des contraintes écologiques et géographiques spécifiques à chaque région.

## REMERCIEMENTS

Nous remercions Olivier Van Lier, spécialiste en télédétection, d'avoir proposé le projet et Miriam Isaac-Renton, chercheuse scientifique chez Ressources naturelles Canada d'avoir fourni les ensembles de données associés. Nous remercions également Olivia Waite et Jacob King (Ressources naturelles Canada) pour la préparation des données cibles.

## RÉFÉRENCES

- [1] Rapport sur le climat changeant du Canada, “Changements de température,” <https://changingclimate.ca/CCC2019/fr/chapitre/sommaire/>, s. d., Consulté le 8 avril 2025.
- [2] A. Holzinger, A. Saranti, A. Angerschmid, C. O. Retzlaff, A. Gronauer, V. Pejakov, F. Medel-Jimenez, T. Krexner, C. Gollob, and K. Stampfer, “Digital transformation in smart farm and forest operations needs human-centered ai : Challenges and future directions,” *Sensors*, vol. 22, no. 8, pp. 3043, 2022.
- [3] Z. Zhen, L. J. Quackenbush, and L. Zhang, “Trends in automatic individual tree crown detection and delineation—evolution of lidar data,” *Remote Sensing*, vol. 8, no. 4, pp. 333, 2016.
- [4] J. Zheng, S. Yuan, W. Li, H. Fu, and L. Yu, “A review of individual tree crown detection and delineation from optical remote sensing images,” *arXiv preprint*, 2023.
- [5] Y. Lin, H. Li, L. Jing, H. Ding, and S. Tian, “Individual tree crown delineation using airborne lidar data and aerial imagery in the taiga-tundra ecotone,” *Remote Sensing*, vol. 16, no. 21, pp. 3920, 2024.
- [6] T. Luo, S. Rao, W. Ma, Q. Song, Z. Cao, H. Zhang, J. Xie, X. Wen, W. Gao, Q. Chen, J. Yun, and D. Wu, “Yolotree-individual tree spatial positioning and crown volume calculation using uav-rgb imagery and lidar data,” *Forests*, vol. 15, no. 8, pp. 1375, 2024.
- [7] M. Freudenberg, N. Nölke, A. Agostini, K. Urban, F. Wörgötter, and C. Kleinn, “Large scale palm tree detection in high resolution satellite images using u-net,” *Remote Sensing*, vol. 11, no. 3, pp. 312, 2019.
- [8] J. Martins, K. Nogueira, L. Osco, F. Gomes, D. Furuya, W. Gonçalves, D. Sant’Ana, A. P. Ramos, V. Liesenberg, J. dos Santos, P. T. Oliveira, and J. Junior, “Semantic segmentation of tree-canopy in urban environment with pixel-wise deep learning,” *Remote Sensing*, vol. 13, no. 16, pp. 3054, 2021.
- [9] Sizhuo L., “sizhuoli/treecountsegheight,” <https://github.com/sizhuoli/TreeCountSegHeight>, s. d., Consulté le 10 avril 2025.
- [10] S. Li, M. Brandt, R. Fensholt, A. Kariryaa, C. Igel, F. Gieseke, T. Nord-Larsen, S. Oehmcke, A. Carlsen, S. Junttila, X. Tong, A. d’Aspremont, and P. Ciais, “Deep learning enables image-based tree counting, crown segmentation and height prediction at national scale,” *PNAS Nexus*, vol. 2, no. 3, pp. pgad076, 2023.
- [11] Sizhuo L., “Pre-trained models,” <https://drive.google.com/file/d/1ZNibrh6pa4-cjXLawua6L96fOKS3uwbn/view?usp=sharing>, s. d., Consulté le 10 avril 2025.
- [12] Alexander Kirillov, Eric Mintun, Nikhila Ravi, Hanzi Mao, Chloe Rolland, Laura Gustafson, Tete Xiao, Spencer Whitehead, Alexander C. Berg, Wan-Yen Lo, Piotr Dollár, and Ross Girshick, “Segment anything,” *arXiv preprint arXiv :2304.02643*, 2023.
- [13] Xiaoyang Wu, Daniel DeTone, Duncan Frost, Tianwei Shen, Chris Xie, Nan Yang, Jakob Engel, Richard Newcombe, Hengshuang Zhao, and Julian Straub, “Sonata : Self-supervised learning of reliable point representations,” *arXiv preprint arXiv :2503.16429*, 2024.
- [14] M. Teng, A. Ouaknine, E. Laliberté, Y. Bengio, D. Rolnick, and H. Larochelle, “Assessing sam for tree crown instance segmentation from drone imagery,” *arXiv preprint arXiv :2503.20199*, 2025.
- [15] S. Speckenwirth, M. Brandmeier, and S. Paczkowski, “Treeseg—a toolbox for fully automated tree crown segmentation based on high-resolution multispectral uav data,” *Remote Sensing*, vol. 16, no. 19, pp. 3660, 2024.
- [16] A. Straker, “You only segment crowns (v1.0.1-alpha),” <https://doi.org/10.5281/zenodo.8362641>, 2023.
- [17] Z. Xi and D. Degenhardt, “A new unified framework for supervised 3d crown segmentation (treeonet) using deep neural networks across airborne, uav-borne, and terrestrial laser scans,” *ISPRS Open Journal of Photogrammetry and Remote Sensing*, vol. 15, pp. 100083, 2025.
- [18] J. Henrich, J. van Delden, D. Seidel, T. Kneib, and A. S. Ecker, “Treelearn : A deep learning method for segmenting individual trees from ground-based lidar forest point clouds,” *Ecological Informatics*, vol. 84, pp. 102888, 2024.
- [19] M. Wielgosz, S. Puliti, B. Xiang, K. Schindler, and R. Astrup, “Segmentanytree : A sensor and platform agnostic deep learning model for tree segmentation using laser scanning data,” *Remote Sensing of Environment*, vol. 313, pp. 114367, 2024.
- [20] B. Xiang, M. Wielgosz, T. Kontogianni, T. Peters, S. Puliti, R. Astrup, and K. Schindler, “Automated forest inventory : Analysis of high-density airborne lidar point clouds with 3d deep learning,” *Remote Sensing of Environment*, vol. 305, pp. 114078, 2024.



# ANNEXE 1 : TABLEAUX SUPPLÉMENTAIRES

TABLE IV – Caractéristiques des sites d'échantillonnage

| Site          | Espèce                         | Nombre d'arbres | Année de plantation | Année des données | Âge des arbres | Résolution des nuages de points (points/m <sup>2</sup> ) | Résolution de l'image multi-spectrale (cm/pixel) |
|---------------|--------------------------------|-----------------|---------------------|-------------------|----------------|----------------------------------------------------------|--------------------------------------------------|
| CW Rainbow A  | Cèdre rouge du Canada (mature) | 1870            | 2000                | 2022              | 22             | 2775                                                     | 4,23                                             |
| CW Rainbow B  | Cèdre rouge du Canada (mature) | 1113            | 2000                | 2022              | 22             | 2437                                                     | 4,67                                             |
| CW East Main  | Cèdre rouge du Canada (mature) | 3724            | 2000                | 2023              | 23             | 4942                                                     | 4,00                                             |
| CW Sandcut    | Cèdre rouge du Canada (jeune)  | 3489            | 2012                | 2022              | 10             | 3561                                                     | 2,59                                             |
| FDC Canoe     | Sapin de douglas (mature)      | 1281            | 1999                | 2022              | 23             | 3364                                                     | 3,50                                             |
| FDC East Main | Sapin de douglas (mature)      | 1585            | 2003                | 2022              | 19             | 7620                                                     | 4,51                                             |
| FDC W45       | Sapin de douglas (jeune)       | 2068            | 2019                | 2023              | 4              | 3726                                                     | 2,48                                             |
| Total         |                                | 15130           |                     |                   |                |                                                          |                                                  |

TABLE V – Revue de l'état de l'art de la segmentation individuelle des arbres

| Nom du modèle                                                            | Approche de segmentation et architecture                                                                                                                                                                                                                                                                                                                                                                                 | Données d'entraînement                                                                                 | Entrée du modèle                                                 | Nombre d'arbres (train) | Type de peuplement                                                                         | Code et modèle pré-entraîné |
|--------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------|------------------------------------------------------------------|-------------------------|--------------------------------------------------------------------------------------------|-----------------------------|
| <b>Approches 2D</b>                                                      |                                                                                                                                                                                                                                                                                                                                                                                                                          |                                                                                                        |                                                                  |                         |                                                                                            |                             |
| Assessing SAM for tree crown segmentation from drone imagery (2025) [14] | Approche de segmentation : Instance. Architecture : SAM, Mask-R-CNN, Prompt pour SAM généré à partir de Faster-R-CNN, Mask-R-CNN, RSPrompter ou DSPPrompter.                                                                                                                                                                                                                                                             | UAV haute-résolution (5mm/pixel)                                                                       | RGB et carte de surface de terrain                               | 19500                   | Principalement des forêts de conifères.                                                    | Non                         |
| TreeSeg (2024) [15]                                                      | Approche de segmentation : Instance. Architecture : Faster R-CNN, Mask R-CNN, TensorMask, SAM.                                                                                                                                                                                                                                                                                                                           | UAV multispectrale (5 bandes, résolution : 1.3-2.3 cm/pixel)                                           | Bandes RGB et cartes d'indices de végétations (ex. NDVI)         | 800                     | Forêts de conifères.                                                                       | Oui                         |
| You Only Segment Crowns (2023) [16]                                      | Approche de segmentation : Instance. Architecture : YOLOv5                                                                                                                                                                                                                                                                                                                                                               | LiDAR UAV (FOR-Instance).                                                                              | Cartes de hauteur de canopée générées à partir des données LiDAR | 2934                    | Principalement des forêts de conifères.                                                    | Non                         |
| TreeCountSegHeight (2023) [10]                                           | Approche de segmentation : Sémantique. Architecture : U-Net avec deux têtes de sorties pour 1) le décompte et la localisation des arbres et 2) pour la segmentation des couronnes.                                                                                                                                                                                                                                       | Images satellites haute-résolution (20 cm/pixel) et carte de haut de canopée (résolution 40 cm/pixel). | RGB, NIR, et cartes d'indices de végétation (ex NDVI)            | 19771                   | 49% forêts décidues dense, 30% forêts de conifères dense, 21% zones non forestières.       | Oui                         |
| <b>Approches 3D</b>                                                      |                                                                                                                                                                                                                                                                                                                                                                                                                          |                                                                                                        |                                                                  |                         |                                                                                            |                             |
| TreeisoNet (2025) [17]                                                   | Approche de segmentation : Instance. Architecture : divisée en 4 problèmes distincts avec 4 réseaux de neurones : 1) classification des tiges (3D-SegFormer); 2) trouver la base de l'arbre (3D-SegFormer); 3) segmentation des tiges (3D U-Net) et 4) clustering de la couronne (3D U-Net).                                                                                                                             | TLS, UAV (FOR-Instance), ALS                                                                           | Nuage de points LiDAR                                            | 3759                    | Types de peuplement variés.                                                                | Non                         |
| Tree Learn (2024) [18]                                                   | Approche de segmentation : Instance. Architecture : 1) Diviser le nuage de points de la forêt; 2) U-Net NN : coordonnées de la base de l'arbre et probabilité qu'un point appartienne ou non à un arbre; 3) fusionner les prédictions pour obtenir des prédictions sémantiques et d'instances; 4) clustering : partitionner les points en arbres individuels; 5) critère du plus proche voisin pour attribuer les points | Sources principales : TLS et MLS, autres : UAV (FOR-Instance)                                          | Nuage de points LiDAR                                            | 6665                    | Types de peuplement variés.                                                                | Oui                         |
| Segment AnyTree (2024) [19]                                              | Approche de segmentation : Panoptique. Architecture : 3D U-Net CNN inspiré par l'architecture PointGroup. Utilise 3 têtes de prédiction en parallèle : une tête pour la segmentation sémantique et deux têtes pour la segmentation d'instance.                                                                                                                                                                           | LiDAR UAV (FOR-Instance) + MLS                                                                         | Nuage de points LiDAR                                            | 1445                    | Principalement des forêts de conifères en zone boréale, un peu de forêts tempérées mixtes. | Oui                         |
| ForAI-Net (2024) [20]                                                    | Approche de segmentation : Sémantique et instance. Architecture : 3D U-Net sparse 3D CNN backbone pour segmentation sémantique et d'instance simultanée. Trois niveaux de segmentation : 1) sémantique avec classes : arbres dominant la canopée, intermédiaire et sous-bois; 2) d'instance; et 3) sémantique par composante de l'arbre (classes : tige, branches).                                                      | LiDAR UAV (FOR-Instance)                                                                               | Nuage de points LiDAR                                            | 1130                    | Principalement des forêts de conifères.                                                    | Oui                         |